EDUCAÇÃO FINANCEIRA ASSISTIDA POR IA: PLATAFORMA DE APOIO PERSONALIZADO COM INTELIGÊNCIA ARTIFICIAL GENERATIVA

Identificação dos autores

1º Autor

Nome: João Gabriel Barreto de Araújo Falcão

E-mail: joao.falcao@cs.unipe.edu.br

Telefone: (83) 98888-0507

2º Autor

Nome: Júlio César Carvalho Santos

E-mail: julio.santos05@cs.unipe.edu.br

Telefone: (83) 98722-0156

3º Autor

Nome: Perilo de Oliveira Viana Sobrinho

E-mail: perilo.sobrinho@cs.unipe.edu.br

Telefone: (83) 98647-3303

4º Autor (orientador)

Nome: Ricardo Dantas Silva

E-mail: ricardods@unipe.edu.br

Telefone:

EDUCAÇÃO FINANCEIRA ASSISTIDA POR IA: PLATAFORMA DE APOIO PERSONALIZADO COM INTELIGÊNCIA ARTIFICIAL GENERATIVA

João G. B. A. Falcão[1], **Júlio C. C. Santos**[1], **Perilo O. V. Sobrinho** [1], **Ricardo Dantas**[1]

[1]Ciência da Computação – Centro Universitário de João Pessoa (UNIPÊ)
João Pessoa – PB – Brasil

{joao.falcao, julioccsantos, perilo.sobrinho, ricardo.dantas}@cs.unipe.edu.br

RESUMO: No que diz respeito às finanças, os brasileiros enfrentam um desafio significativo, refletido na carência de educação financeira. Pesquisas realizadas pelo Instituto de Pesquisas Sociais, Políticas e Econômicas (IPESPE) sugerem que grande parte dos brasileiros possui pouco ou nenhum entendimento sobre o tema. Embora sistemas tradicionais de controle financeiro auxiliem no acompanhamento de receitas e despesas, a ausência de conhecimento adequado limita a tomada de decisões eficazes. Nesse contexto, a integração de informações com o uso de Inteligência Artificial Generativa, especialmente por meio de Modelos de Linguagem de Grande Escala (LLMs), surge como uma alternativa promissora para orientar os usuários de forma personalizada e didática. Este trabalho tem como objetivo projetar e desenvolver uma aplicação web de gestão financeira acompanhada de uma LLM, viabilizando sua aplicação prática no contexto da educação financeira.
Palavras-chave: Inteligência Artificial; LLMs; RAG; Aplicação Web; Educação Financeira.

ABSTRACT: *Regarding finances, Brazilians face a significant challenge, reflected in a lack of financial literacy. Research conducted by Instituto de Pesquisas Sociais, Políticas e Econômicas (IPESPE) that a large portion of Brazilians have little or no understanding of the subject. Although traditional financial control systems help monitor income and expenses, the absence of adequate knowledge limits effective decision-making. In this context, the integration of information using Generative Artificial Intelligence, especially through Large Language Models (LLMs), emerges as a promising alternative to guide users in a personalized and didactic way. This work aims to design and develop a web-based financial management application integrated with an LLM, enabling its practical use in financial education.*

1. INTRODUÇÃO

1.1. MOTIVAÇÃO E JUSTIFICATIVA

De acordo com a pesquisa Observatório Febraban, realizada pelo Instituto de Pesquisas Sociais, Políticas e Econômicas (IPESPE) [FEBRABAN 2025], aproximadamente 40% dos brasileiros afirmam possuir pouco conhecimento sobre educação financeira, enquanto 15% declaram não possuir entendimento sobre o tema, o que evidencia que a saúde financeira da população brasileira constitui um desafio estrutural relevante. Segundo a Organização para a Cooperação e Desenvolvimento Econômico [OCDE 2023], baixos níveis de educação financeira impactam diretamente a capacidade dos indivíduos de realizar planejamentos econômicos adequados e tomar decisões financeiras conscientes. Nesse contexto, a pesquisa também demonstra que, embora a maioria dos entrevistados reconheça a importância da educação financeira, ainda existem

limitações significativas no acesso ao conhecimento necessário para o planejamento e controle adequados das finanças pessoais [FEBRABAN 2025].

Estudos demonstram que o uso de aplicações financeiras digitais apresenta-se como ferramentas que podem contribuir para a melhoria da tomada de decisões econômicas ao ampliar o acesso às informações financeiras dos usuários [Carlin et al. 2023]. No entanto, tal solução, isoladamente, não é suficiente, uma vez que, conforme estabelece a Comissão de Valores Mobiliários [CVM - Comissão de Valores Mobiliários 2022], a educação financeira influencia diretamente o comportamento dos indivíduos e sua capacidade de interpretar informações e tomar decisões adequadas voltadas ao bem-estar financeiro, de modo que a ausência de conhecimento financeiro pode comprometer a compreensão dos dados disponibilizados por essas ferramentas e reduzir seu potencial de contribuição para a melhoria da saúde econômica dos indivíduos.

Diante desse cenário, a integração entre a centralização de informações financeiras e a utilização de Inteligência Artificial Generativa apresenta-se como uma promissora solução para auxiliar o usuário de forma mais ativa e personalizada. Segundo [Li et al. 2023], Modelos de Linguagem de Grande Escala (LLMs) têm demonstrado capacidade de interpretar dados, identificar padrões e fornecer orientações em linguagem natural, o que pode contribuir significativamente para a educação financeira do usuário.

Assim, surge o seguinte questionamento: como a adição de uma inteligência artificial generativa a um sistema de controle financeiro pode oferecer suporte e colaborar com a educação financeira do usuário? Mais especificamente, busca-se analisar a capacidade de um modelo de identificar problemas financeiros, fornecer orientações didáticas e contribuir para a tomada de decisões financeiras mais assertivas, conscientes e sustentáveis. Este estudo visa projetar, desenvolver e avaliar a viabilidade dessa integração em um protótipo de aplicação web focada em educação financeira personalizada, ampliando o acesso a ferramentas inteligentes de apoio à gestão econômica individual.

1.2. OBJETIVO GERAL

O objetivo deste trabalho foi desenvolver uma aplicação web assistida por LLMs, capaz de fornecer diagnósticos e orientações financeiras personalizadas no contexto da gestão pessoal. Buscava-se analisar de que formas essa tecnologia pode interpretar informações financeiras, identificar padrões, reconhecer problemas relacionados à organização monetária e oferecer recomendações em linguagem clara e acessível. Sob esse viés, a construção do protótipo visou validar a eficácia da integração da inteligência artificial na assistência à educação financeira, demonstrando ser viável como ferramenta de apoio à gestão econômica individual, de modo a ampliar o acesso a soluções inteligentes que auxiliem os usuários na construção de hábitos financeiros conscientes, sustentáveis e alinhados aos seus objetivos pessoais.

1.3. OBJETIVOS ESPECÍFICOS

- Mapear os principais conceitos de finanças pessoais, estruturando uma base de conhecimento que serviu de referência para o sistema.
- Desenvolver a arquitetura e a interface da aplicação web capaz de coletar dados financeiros do usuário, rastrear seus hábitos e processar essas informações por meio de dashboards informativos.
- Integrar um modelo de LLM ao sistema por meio da técnica de Retrieval-Augmented Generation (RAG), conectando as IAs à base de dados previamente estruturada.
- Analisar o desempenho do modelo integrado a partir de cenários financeiros simulados, avaliando, por meio de métricas técnicas, como o tempo de resposta, e de métricas qualitativas, como a ausência de alucinações e a utilidade das recomendações geradas.

1.4. ESTRUTURA DO TRABALHO

O artigo está estruturado da seguinte forma: a seção 1 apresenta a introdução, contemplando a contextualização do tema, a justificativa/motivação da pesquisa, além dos objetivos gerais e específicos da pesquisa. A seção 2 explica a metodologia adotada, detalhando os procedimentos para o desenvolvimento do estudo, incluindo a construção da base de conhecimento em finanças pessoais e a integração da LLM por meio de RAG. A seção 3 aborda a fundamentação teórica, reunindo os principais conceitos relacionados ao estudo, como conceitos relacionados à educação financeira e às tecnologias de desenvolvimento de software e de Inteligência Artificial utilizadas no decorrer do estudo.

2. METODOLOGIA

Essa seção especifica os caminhos seguidos durante o processo e classifica cientificamente o estudo, as definições de arquitetura e os critérios comparativos entre as LLMs

2.1. CLASSIFICAÇÃO DA PESQUISA

Esta pesquisa possui por objetivo ser aplicada, exploratória, bibliográfica e experimental. [Gil 2022] afirma que a pesquisa aplicada é voltada à aquisição de conhecimento com foco em aplicação numa situação específica. Neste escopo, a finalidade prática reside no desenvolvimento de uma solução tecnológica em formato de aplicação web capaz de sanar dúvidas e contribuir para o letramento financeiro pessoal. Além disso, a natureza exploratória é justificada pela pesquisa ter como propósito "proporcionar maior familiaridade com o problema, com vistas a torná-lo mais explícito e construir hipóteses" [Gil 2022].

Em relação à fundamentação teórica para o mapeamento dos conceitos de finanças e economia comportamental, foi adotada a pesquisa bibliográfica, que "é elaborada com base em material já publicado" [Gil 2022]. De forma complementar, adotou-se a pesquisa experimental que, de acordo com [Gil 2022], tem como propósito determinar um objeto de estudo, selecionar as variáveis que o influenciam e definir formas de controle, presentes por meio da prototipagem do software, em que, dentro de cenários controlados, validam-se as interações entre o usuário, o sistema e o modelo de inteligência artificial generativa

2.2. ARQUITETURA DO SISTEMA

Para tornar o teste dos modelos viável em um cenário em que um usuário do sistema fornece as informações, foi necessário o desenvolvimento de um protótipo fundamentado em uma arquitetura cliente-servidor.

A interface de usuário adotou a tecnologia do ecossistema React, por meio do framework Next.js e TypeScript. Essa escolha garantiu a tipagem estática do código e de componentes interativos na renderização dos dashboards financeiros.

A lógica de negócios e a comunicação com o banco de dados PostgreSQL foram estruturadas em uma API Python, utilizando Django REST. O servidor foi responsável por receber os dados inseridos pelo usuário, processá-los, estruturá-los em um prompt em formato JSON e gerenciar as requisições HTTP para o modelo de linguagem.

2.3. INTEGRAÇÃO DA INTELIGÊNCIA ARTIFICIAL E RAG

A integração da inteligência artificial ocorreu utilizando a técnica de Retrieval-Augmented Generation (RAG), baseada em uma abordagem de recuperação contextual de informações. Para a implementação da solução, foi adotada uma arquitetura RAG 2.0, na qual os dados recuperados

passaram por uma etapa adicional de processamento e contextualização antes de serem enviados ao modelo de linguagem, permitindo respostas mais específicas e alinhadas ao domínio da aplicação.

A base de conhecimento foi estruturada utilizando um banco de dados vetorial, responsável pelo armazenamento de embeddings gerados a partir de informações financeiras do usuário e conteúdos técnicos relacionados a educação financeira. Entre as tecnologias consideradas para essa finalidade estão ferramentas como FAISS (Facebook Al Similarity Search) ou ChromaDB, que possibilitam a indexação e recuperação eficiente de informações semânticas relevantes.

A implementação do fluxo de integração entre os componentes da arquitetura decorreu da implementação e da utilização do framework LangChain, responsável pela orquestração das etapas de geração de embeddings, recuperação de documentos relevantes e construção do contexto enviado ao modelo de linguagem.

O modelo de linguagem foi integrado por meio da API da OpenAI, sendo responsável pela interpretação dos dados recuperados e pela geração das respostas em linguagem natural. Dessa forma, o sistema anexou ao contexto da requisição tanto o histórico financeiro do usuário quanto informações provenientes da base de conhecimento, permitindo que o modelo utilize dados específicos durante o processo de geração. Essa estratégia contribuiu para reduzir riscos de alucinação e aumentar a consistência das respostas produzidas.

3. FUNDAMENTAÇÃO TEÓRICA

Esta seção do estudo apresenta os principais conceitos e tecnologias que fundamentam o desenvolvimento deste trabalho. Inicialmente, são abordados aspectos da Engenharia de Software, seguidos por conceitos da área de Economia com foco na saúde financeira pessoal. Por fim, são apresentados os fundamentos de Inteligência Artificial com ênfase em LLMs e em técnicas como Retrieval-Augmented Generation (RAG).

3.1. ECONOMIA

Conforme aponta [Marchevsky 2023], as ideias clássicas de Adam Smith sobre o livre mercado e a divisão do trabalho ainda são o ponto de partida para entender como a economia gera valor. No entanto, o autor mostra que, hoje em dia, a economia vai muito além das grandes indústrias e da produção nacional, passando a olhar de perto para a vida financeira das pessoas comuns no seu cotidiano. Nesse viés, o autor acredita que nos tempos contemporâneos a realidade exige que cada indivíduo saiba como equilibrar seu próprio bolso, controlando o consumo e desenhando um planejamento financeiro realista, pois é exatamente no dia a dia que variáveis como juros, inflação e o uso do crédito mexem com o orçamento das famílias. Por isso, o estudo conclui que entender como o mercado funciona na prática virou uma questão de sobrevivência: quando as pessoas não dominam esses conceitos, as chances de cair na armadilha do endividamento e da inadimplência disparam, o que acaba prejudicando a saúde financeira dos indivíduos.

3.1.1. JUROS

Na definição de [Assef 2024], os juros representam o custo do dinheiro ao longo do tempo, funcionando como a remuneração pelo uso de um capital em operações de empréstimo, financiamento ou investimento. O autor explica que esse custo pode ser calculado de forma simples ou composta, impactando diretamente o valor final que será pago ou recebido pelo investidor. Complementando essa visão, [Kobori 2024] destaca em sua obra que os juros exercem um papel

essencial na dinâmica e nas decisões financeiras individuais. Para Kobori, as taxas de juros influenciam diretamente o poder de consumo das famílias, o acesso ao crédito e, principalmente, a capacidade de formação de patrimônio da população ao longo do tempo.

3.1.2. INFLAÇÃO

Conforme dados oficiais do [Banco Central do Brasil 2024], a inflação é caracterizada pelo aumento generalizado e contínuo dos preços de bens e serviços em uma economia ao longo do tempo. Para a autarquia, esse fenômeno reduz de forma direta o poder de compra da moeda, fazendo com que uma mesma quantia adquira menos produtos. Em consonância com essa visão, [Kobori 2024] explica em sua obra que a inflação está diretamente associada ao desequilíbrio entre a oferta e a demanda monetária. O autor ressalta que a expansão da base monetária, quando não é acompanhada pelo crescimento real da produção, tende a intensificar a elevação dos preços. Esse cenário é um reflexo direto das decisões de política monetária no Brasil, cujos impactos no controle inflacionário e na estabilidade econômica são fundamentais para proteger a renda da população [Flora and Santolin 2024].

3.1.3. INADIMPLÊNCIA

Na perspectiva de [Kobori 2024], a inadimplência é o reflexo direto do descumprimento de obrigações financeiras por parte de indivíduos ou empresas, identificada pelo atraso ou não pagamento de dívidas no prazo acordado. Em sua obra, o autor explica que esse fenômeno está frequentemente associado à falta de planejamento pessoal e ao uso inadequado de linhas de crédito pelas famílias. Sob essa ótica, Kobori defende que a educação financeira exerce um papel fundamental e preventivo, funcionando como a principal ferramenta para mitigar o endividamento excessivo e garantir a sustentabilidade da saúde financeira da população.

3.1.4. SAÚDE FINANCEIRA PESSOAL

Na visão de [Lazaretti Júnior et al. 2024], a saúde financeira pessoal baseia-se diretamente na capacidade que o indivíduo tem de equilibrar sua renda com as despesas diárias, mantendo o controle sobre suas obrigações financeiras imediatas e futuras. Para os autores, esse conceito está intimamente ligado à organização, ao uso consciente do crédito e à tomada de decisões que garantam estabilidade ao longo do tempo. Eles apontam que o desenvolvimento de uma saúde financeira robusta depende de programas contínuos de alfabetização financeira, os quais são fundamentais para capacitar o cidadão a mitigar os riscos do endividamento e a exercer escolhas de consumo muito mais conscientes e sustentáveis.

3.1.5. ECONOMIA COMPORTAMENTAL

De acordo com [Housel 2021], o sucesso financeiro está muito mais ligado ao comportamento humano e à maneira como lidamos com o dinheiro do que ao conhecimento técnico ou matemático em si. Sob essa ótica, a Economia Comportamental ganha relevância ao estudar como fatores psicológicos, emocionais e cognitivos influenciam as escolhas financeiras dos indivíduos. O autor argumenta que as decisões do dia a dia não são tomadas puramente com base em planilhas ou fórmulas, mas são moldadas diretamente pelas emoções, pelos hábitos cotidianos e pelas experiências pessoais de cada investidor.

3.2. ENGENHARIA DE SOFTWARE

De acordo com [Ciriano and Scombatti Pinto 2025], o avanço dos sistemas computacionais e a crescente integração entre tecnologias ampliaram a necessidade de métodos estruturados para o desenvolvimento de software. Os autores retomam fundamentos clássicos da área ao destacar

que Pressman e Maxim (2020) definem a Engenharia de Software como a aplicação sistemática de princípios, métodos e práticas voltadas ao desenvolvimento e manutenção de sistemas computacionais de forma organizada e eficiente. Dessa forma, a Engenharia de Software assume papel essencial na construção de aplicações modernas ao fornecer mecanismos que favorecem organização estrutural, comunicação entre componentes e maior flexibilidade no desenvolvimento de sistemas.

3.2.1. ARQUITETURA CLIENTE-SERVIDOR

[Ciriano and Scombatti Pinto 2025] apontam que a evolução das arquiteturas de software ocorreu em resposta às demandas por escalabilidade, flexibilidade e melhor organização estrutural dos sistemas computacionais. Os autores ressaltam que aplicações modernas passaram a exigir modelos capazes de distribuir responsabilidades e facilitar a comunicação entre componentes, tornando a arquitetura cliente-servidor uma das abordagens mais empregadas em ambientes distribuídos.

Nessa perspectiva, os autores destacam que estudos clássicos de Sommerville (2019) definem a arquitetura cliente-servidor como um modelo em que as responsabilidades do sistema são divididas entre clientes e servidores. Enquanto o cliente é responsável pela interação com o usuário e pela solicitação de recursos, o servidor realiza o processamento das requisições, executa regras de negócio e disponibiliza os serviços solicitados. Essa separação estrutural reduz a dependência entre componentes e contribui para uma organização mais eficiente do sistema.

Complementando essa visão, os autores (2025) também reforçam, a partir dos fundamentos apresentados por Bass, Clements e Kazman, que modelos arquiteturais modernos buscam favorecer características como modularidade, facilidade de manutenção e escalabilidade. Sob essa perspectiva, aplicações web utilizam amplamente a arquitetura cliente-servidor para separar a camada responsável pela interface do usuário das camadas relacionadas ao processamento de dados e gerenciamento das informações, permitindo o desenvolvimento de aplicações mais flexíveis e adequadas a ambientes distribuídos

3.2.2. API'S E INTEGRAÇÃO DE SISTEMAS

[Ciriano and Scombatti Pinto 2025] destacam que a evolução das arquiteturas modernas ampliou a necessidade de mecanismos que permitam comunicação eficiente entre diferentes componentes e serviços computacionais. Nesse cenário, a integração entre sistemas passou a desempenhar papel importante para garantir interoperabilidade e flexibilidade em aplicações distribuídas. Sob essa perspectiva, estudos apresentados por Sommerville (2019) definem APIs (Application Programming Interfaces) como mecanismos responsáveis por estabelecer regras e padrões de comunicação entre sistemas distintos, permitindo o compartilhamento padronizado de dados e funcionalidades. Essa abordagem reduz o acoplamento entre aplicações e facilita a integração entre diferentes serviços, contribuindo para o desenvolvimento de sistemas mais organizados e escaláveis.

3.3. INTELIGÊNCIA ARTIFICIAL

A gênese da Inteligência Artificial (IA) remonta à década de 1960 com o famoso Teste de Turing. Esse modelo funcionou como um ponto de partida para discutir se as máquinas poderiam, de fato, simular o pensamento humano [Russell and Norvig 2022]. No início, cientistas como John McCarthy acreditavam que, para uma máquina ser inteligente, ela precisaria seguir regras

lógicas rígidas e tentar imitar o senso comum humano. Porém, com o passar dos anos, esse modelo se mostrou limitado [Gabriel Filho 2023]. Hoje, a IA moderna funciona de um jeito totalmente diferente. Em vez de apenas seguir ordens pré-programadas em um banco de dados fixo, os sistemas atuais utilizam o Aprendizado de Máquina para analisar grandes volumes de dados e aprender com eles de forma autônoma, adaptando-se a novas situações [Faceli et al. 2025].

3.3.1. MACHINE LEARNING

Conforme destacado por [Barbierato and Gatti 2024], o Machine Learning (Aprendizado de Máquina) é uma subárea da Inteligência Artificial voltada ao desenvolvimento de algoritmos capazes de aprender a partir de dados e generalizar comportamentos para novas situações por meio de métodos estatísticos e computacionais. Por meio da identificação de padrões e relações, esses sistemas conseguem realizar previsões, reconhecer comportamentos e auxiliar processos de tomada de decisão em diferentes contextos. Nesse sentido, os avanços recentes em aprendizado de máquina têm impulsionado significativamente a evolução dos sistemas de Inteligência Artificial e ampliado sua aplicação em diversas áreas da sociedade.

3.3.2. LLM

Segundo [Minaee et al. 2024], os Modelos de Linguagem de Grande Escala (LLMs) são sistemas avançados de Inteligência Artificial treinados com grandes volumes de dados, capazes de compreender, processar e gerar linguagem natural de forma semelhante à humana. Além disso, estudos recentes destacam a evolução desses modelos para arquiteturas multimodais, capazes de integrar diferentes tipos de dados, como texto, imagens e áudio, ampliando suas capacidades de interpretação e interação contextual [Huang et al. 2024]. Conforme os autores, os modelos utilizam técnicas de aprendizado profundo para identificar padrões linguísticos e contextuais, permitindo sua aplicação em tarefas como geração de texto, análise de informações e suporte à tomada de decisão.

3.3.3. RAG

Segundo [Gao et al. 2024], a técnica Retrieval-Augmented Generation (RAG) consiste em um processo de otimização das respostas geradas por LLMs, no qual o modelo consulta uma base de dados externa e confiável durante a geração das respostas. Dessa forma, o artigo conceitua que o RAG combina os conhecimentos pré-treinados do modelo com informações atualizadas e específicas, reduzindo erros e aumentando a qualidade das respostas. Para os autores, essa abordagem melhora a precisão e a confiabilidade dos sistemas baseados em linguagem natural.

4. DESENVOLVIMENTO

4.1. MAPEAMENTO DA BASE DE CONHECIMENTO FINANCEIRO

Para capacitar o sistema a fornecer respostas confiáveis e contextualizadas, realizou-se o mapeamento dos principais conceitos de finanças pessoais, gestão orçamentária e economia comportamental. O núcleo consultivo da base foi estruturado a partir dos seguintes documentos: o Caderno de Educação Financeira do Banco Central do Brasil, a coleção TOP de Planejamento Financeiro Pessoal, o Caderno CVM Volume 1: Vieses do Investidor e as diretrizes da Estratégia Nacional de Educação Financeira (ENEF).

A transformação desse material normativo e extenso em artefatos indexáveis demandou um *pipeline* estruturado de pré-processamento, particionamento semântico e enriquecimento de metadados. A primeira etapa consistiu na limpeza dos documentos, removendo elementos que não agregam valor semântico, como capas, sumários, rodapés, exercícios e créditos.

Em seguida, em vez de um extrator de PDF tradicional, que tende a desconstruir a ordem lógica dos documentos, foi utilizado o *Docling*. A biblioteca utiliza modelos de visão computacional voltados ao reconhecimento avançado de *page layout* e estruturas tabulares, preservando a coesão semântica de parágrafos, cabeçalhos e tabelas.

O particionamento foi executado com o mecanismo *HybridChunker*, calibrado para um limite de 450 *tokens*, dimensionamento compatível com a janela do modelo de vetorização *sentence-transformers/paraphrase-multilingual-mpnet-base-v2*. Para evitar que os blocos ficassem curtos demais ou incompletos, configurou-se o agrupamento de trechos vizinhos e a repetição dos cabeçalhos em tabelas que foram divididas.

Por fim, cada pedaço de texto recebeu metadados essenciais: um identificador único, o documento de origem, as páginas correspondentes, a seção e o assunto principal. Dessa forma, além de encontrar o conteúdo pelo contexto, a IA consegue indicar com precisão a fonte e a página consultada, o que ajuda a evitar respostas inventadas ou imprecisas.

O resultado desta etapa consiste em um arquivo consolidado contendo os fragmentos estruturados, conforme ilustrado na Figura 1. Essa padronização permite tanto a busca semântica pelo conteúdo textual quanto a extração direta dos metadados para citação e auditoria pelo sistema.

caderno_cidadania_financeira_tratado_c0079 — JavaScript

```
{
  "chunk_id": "caderno_cidadania_financeira_tratado_c0079",
  "conteudo": "3.5 Endividamento\nDe modo geral, divida corresponde a tudo
aquilo que adquirimos ou usufruimos e pelo qual ainda nao pagamos...",
  "metadados": {
    "documento_origem": "caderno_cidadania_financeira_tratado.pdf",
    "paginas": [35, 36],
    "secoes": "3.5 Endividamento",
    "topico_canonico": "Gestao de Dividas e Juros"
  }
}
```

Figura 1. Exemplo da estrutura JSON de um fragmento indexável gerado no pipeline.

A partir dessa organização, cada partição preserva seu identificador único e a hierarquia temática do documento original. Com isso, o pipeline garante a integridade das referências normativas durante as consultas realizadas pela inteligência artificial.

4.2. ARQUITETURA E DESENVOLVIMENTO DA APLICAÇÃO WEB

4.2.1. *BACK-END:* IMPLEMENTAÇÃO E ARQUITETURA

O *back-end* é desenvolvido em Python utilizando o *framework* Django e o Django REST Framework para a construção de uma API REST. A escolha do Django considera sua estrutura consolidada para aplicações web, seus recursos de organização e o ecossistema disponível para autenticação, persistência e processamento de dados. O Django REST Framework complementa essa estrutura ao facilitar a criação de *endpoints*, a serialização de objetos e a validação das informações recebidas pelas requisições HTTP.

A manipulação dos dados utiliza o ORM (*Object-Relational Mapping*) do Django, que permite representar as entidades do sistema por meio de classes Python e realizar operações

no banco de dados sem exigir a escrita manual de SQL (*Structured Query Language*) para as operações mais comuns. Essa abordagem favorece a legibilidade e a manutenção do código, além de facilitar a definição de relacionamentos e restrições entre as entidades.

O PostgreSQL foi escolhido como sistema gerenciador de banco de dados por seu suporte ao modelo relacional, à integridade referencial e às transações, aspectos importantes para uma aplicação que manipula informações financeiras. A utilização de tipos de dados adequados e de operações transacionais contribui para manter a consistência dos registros durante alterações que envolvem diferentes entidades. Adicionalmente, a extensão pgvector permite armazenar e consultar representações vetoriais no próprio PostgreSQL, oferecendo uma alternativa para implementar mecanismos de busca semântica e recuperação de informações utilizados em abordagens de RAG (*Retrieval-Augmented Generation*).

A autenticação da API utiliza a biblioteca Simple JWT, que implementa autenticação baseada em *tokens* JSON Web Token (JWT). Após a autenticação, o cliente utiliza o *token* de acesso para realizar requisições aos *endpoints* protegidos. O *back-end* também valida as permissões de cada operação, garantindo que os usuários acessem somente os dados autorizados.

Para tarefas que não precisam ser executadas durante o processamento imediato de uma requisição, o sistema utiliza Celery como mecanismo de execução assíncrona e Redis como intermediário de comunicação entre a aplicação e os trabalhadores responsáveis pelas tarefas. Essa separação permite executar processamentos em segundo plano, reduzindo a dependência entre a resposta da API e a conclusão de operações potencialmente demoradas. O Celery Beat complementa essa estrutura ao permitir o agendamento periódico de tarefas, como rotinas de manutenção e processamentos programados.

As principais funcionalidades implementadas no *back-end* envolvem o gerenciamento de receitas e despesas, a classificação por categorias, a definição de limites de gastos, o registro de movimentações recorrentes, a calculadora de juros compostos e o controle do saldo do usuário. Essas funcionalidades são sustentadas por regras de negócio que consideram o tipo, o valor e o estado de cada movimentação. Para evitar inconsistências no saldo, as operações consideram o impacto financeiro anterior e posterior às alterações, utilizando transações e mecanismos de controle de concorrência quando necessário. O sistema também preserva o histórico de determinados registros por meio da desativação lógica (*soft delete*), evitando sua remoção imediata e mantendo informações relevantes para auditoria e conformidade legal.

4.2.2. *FRONT-END:* IMPLEMENTAÇÃO E ARQUITETURA

Para viabilizar o uso prático da ferramenta e a interação do usuário com o agente inteligente, desenvolveu-se uma aplicação web baseada em uma arquitetura moderna orientada a componentes. A escolha do ecossistema centrado no *Next.js* (acompanhado por *React* e *TypeScript*) decorreu da necessidade de conciliar alta densidade interativa e desempenho crítico para uma aplicação de finanças pessoais com suporte a PWA (*Progressive Web App*) [Carlin et al. 2023]. No contexto de gestão financeira diária, atrasos perceptíveis no carregamento inicial ou lentidão em conexões móveis frequentemente levam ao abandono do registro de despesas. O *Next.js* endereça essa restrição por meio de sua arquitetura híbrida: a casca estrutural (*layout.tsx*) opera como *Server Component* garantindo *First Contentful Paint* otimizado, enquanto as telas dinâmicas executam como *Client Components* para sustentar interfaces reativas em tempo real. A tipagem estrita via *TypeScript* garantiu a segurança no tráfego de dados monetários entre a interface e os serviços.

Complementando a engenharia de interface, a camada visual foi orientada por um *Design System* estruturado no espaço de cor OKLCH, garantindo uniformidade perceptual e con-

formidade com os critérios de contraste da norma WCAG 2.1 AA. Afastando-se de painéis contábeis puramente estáticos, a interface incorpora o pilar pedagógico do TCC no fluxo diário de uso (*Just-in-Time Learning*), exibindo insights contextuais gerados pela inteligência artificial de forma integrada ao painel do usuário. Para a gestão de dados, o estado global da aplicação foi unificado via *React Context API* com cache local, adotando o padrão de Atualizações Otimistas (*Optimistic UI*), em que o cadastro de despesas reflete imediatamente no saldo, com identificadores temporários, enquanto a requisição de rede ocorre em segundo plano. Toda a formulação matemática foi desacoplada em um motor puro e agnóstico a *frameworks*, permitindo testes unitários determinísticos.

No que tange à resiliência de entradas, a validação ocorre de forma antecipada (*fail-fast*) por meio da biblioteca Zod acoplada ao *React Hook Form*, tratando máscaras de moeda brasileira antes da submissão. Ademais, uma camada centralizadora traduz as respostas de validação do *Django REST Framework* em mapas de erro semânticos exibidos diretamente nos campos dos formulários. Por fim, para assegurar a confiabilidade do sistema, a aplicação foi estruturada sobre uma suíte robusta de testes automatizados com o executor Vitest e a biblioteca React Testing Library, contemplando testes unitários para os casos de borda do motor financeiro, testes de integração para os interceptadores de autenticação e comunicação de rede, e testes de componentes voltados à simulação de formulários, interações com o agente inteligente e renderização correta das citações documentais.

4.2.3. INTEGRAÇÃO COM INTELIGÊNCIA ARTIFICIAL

A integração com inteligência artificial é realizada por meio de um *AI Gateway* desenvolvido com FastAPI, responsável por intermediar a comunicação entre o *back-end* principal e o modelo de LLM GPT-6 Luna, utilizando a API da OpenAI. Essa camada é estruturada com o auxílio do *framework* LangChain, facilitando a composição dos fluxos de processamento, a recuperação de informações e a integração com os modelos.

Para aprimorar a qualidade e a contextualização das respostas, é utilizada a técnica de RAG, que combina a recuperação de informações contextuais com a geração de respostas em linguagem natural. A solução utiliza o PostgreSQL com a extensão pgvector para armazenar e consultar representações vetoriais, permitindo recuperar conteúdos semanticamente relacionados às perguntas dos usuários. Além dos dados financeiros autorizados, o módulo pode consultar materiais de referência previamente selecionados e processados, fornecendo ao modelo informações complementares para fundamentar suas respostas.

Também são implementados *guardrails* de entrada e saída, mecanismos destinados a validar as consultas recebidas e as respostas geradas, reduzindo riscos como solicitações inadequadas, tentativas de manipulação do modelo (*prompt injection*) e respostas incompatíveis com as restrições definidas para a aplicação. Nesse contexto, o *back-end* principal permanece responsável pela autenticação, autorização e integridade dos dados financeiros, enquanto o *AI Gateway* fica encarregado do fluxo de inteligência artificial, desde a preparação do contexto até a geração e validação das respostas.

Referências

Assef, R. (2024). *Princípios de Finanças e Mercado Financeiro*. Editora FGV, Rio de Janeiro.

Banco Central do Brasil (2024). O que é inflação? Acesso em: 11 mai. 2026.

Barbierato, E. and Gatti, A. (2024). The challenges of machine learning: A critical review. *Electronics*, 13(2):416.

Carlin, B., Olafsson, A., and Pagel, M. (2023). Mobile apps and financial decision making. *Review of Finance*, 27(3):977–996.

Ciriano, G. and Scombatti Pinto, G. (2025). *The Evolution of Software Architecture: From Monolith to Microservices*.

CVM - Comissão de Valores Mobiliários (2022). Portaria CVM/PTE/Nº 91, de 06 de julho de 2022. aprova a política de educação financeira da comissão de valores mobiliários.

Faceli, K., Lorena, A. C., Gama, J., and Carvalho, A. C. P. L. F. (2025). *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. LTC, Rio de Janeiro.

FEBRABAN (2025). Portal FEBRABAN. Acesso em: 02 mar. 2026.

Flora, M. S. and Santolin, R. (2024). Dominância fiscal e dominância monetária para o brasil: uma análise empírica a partir de projeções locais no período de 1999 a 2022. *Nova Economia*.

Gabriel Filho, O. (2023). *Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações*. Blucher, São Paulo.

Gao, Y., Xiong, Y., Wang, X., Wang, K., Jiang, N., Dong, H., Chen, J., Li, S., Xu, R., Wang, Y., et al. (2024). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2. Acesso em: 16 mai. 2026.

Gil, A. C. (2022). *Como elaborar projetos de pesquisa*. Atlas, São Paulo, 7 edition.

Housel, M. (2021). *A Psicologia Financeira: Lições Atemporais sobre Fortuna, Ganância e Felicidade*. HarperCollins, Rio de Janeiro.

Huang, D., Yan, C., Li, Q., and Peng, X. (2024). From large language models to large multimodal models: A literature review. *Applied Sciences*, 14(12):5068.

Kobori, J. (2024). *A fábula do estado da ilha: como a economia e os mercados funcionam*. Alta Books, Rio de Janeiro.

Lazaretti Júnior, R. C., Castanheira, G. d. S., and Maschio, P. A. S. (2024). A importância da educação financeira no brasil. *RECIMA21 - Revista Científica Multidisciplinar*, 5(12):e5126104.

Li, Y., Wang, S., Ding, H., and Chen, H. (2023). Large language models in finance: A survey. *arXiv preprint arXiv:2311.10723*, 2. Acesso em: 16 mai. 2026.

Marchevsky, J. F. (2023). A gramática das trocas na obra de adam smith. *Nova Economia*, 32(3).

Minaee, S., Mikolov, T., Nikzad, N., Chenaghlu, M., Socher, R., Amatriain, X., and Gao, J. (2024). Large language models: A survey. *arXiv preprint arXiv:2402.06196*.

OCDE (2023). Financial education. Acesso em: 02 mar. 2026.

Russell, S. and Norvig, P. (2022). *Inteligência Artificial: Uma Abordagem Moderna*. LTC, Rio de Janeiro, 4 edition.